

Earth Embedding Benchmarks for Geospatial Prediction

1. Imagen satelital

La primera cosa que hay que se lee en las notas es que a diferencia de una foto normal la imagen satelital tiene 13 capas que se llaman bandas y miden otras cosas como tipos de luz reflejada: luz visible, infrarrojo, etc. Cada una de estas capas busca entender algo distinto del lugar.

Esto se representa como un tensor con forma (C, H, W): C bandas, H píxeles de alto, W píxeles de ancho. Cada pixel tiene 13 valores simultáneos. Un bosque, una zona urbana y un cuerpo de agua se ven muy distintos en esas 13 bandas aunque a simple vista parezcan parecidos.

2. El Vision Transformer

Patchification: primero se corta la imagen en cuadros iguales llamados patches. Una imagen de 512×512 con parches de 32×32 produce 256 patches. Cada patch se aplanan en un vector y se convierte en un “token” que sería el equivalente de una palabra en NLP. Si los parches son más grandes se obtiene una secuencia más corta y se pierde detalle; si son más chicos la secuencia es más larga y más costosa.

Proyección lineal: cada token se transforma a la dimensión de trabajo del modelo mediante una multiplicación de matrices. Este paso es aprendido, el modelo decide qué combinaciones de píxeles dentro del parche son informativas.

Positional encoding: un Transformer no sabe en qué orden están sus tokens los trata como un conjunto desordenado. Para que sepa de dónde viene cada patch en la imagen, se le suma a cada token un vector de posición aprendido. Sin esto, una imagen revuelta y una correcta serían idénticas para el modelo.

CLS token: antes de procesar, se agrega al frente de la secuencia un token especial que no viene de ningún patch. Su trabajo es acumular un resumen global de la imagen a medida que el modelo procesa todos los demás tokens. Al final, ese token es el embedding.

Self-attention: el mecanismo que hace poderoso al Transformer. Cada token puede mirar a todos los demás y decidir cuánto tomar de cada uno. Un patch de carretera puede consultar a sus vecinos para saber si está en una autopista o una calle residencial.

3. Masked Autoencoder

EL Masked Autoencoder (MAE) funciona dándole una imagen, ocultas aleatoriamente el 75% de sus parches, y le pides al modelo que reconstruya lo que falta a partir del 25% que sí puede ver. El error entre la reconstrucción y la imagen original es la señal de entrenamiento. No hay ninguna etiqueta humana en ningún paso.

Con menos del 75% oculto, el modelo puede hacer trampa: interpola desde los píxeles vecinos sin necesidad de entender el contenido.

Una vez terminado el entrenamiento, el decoder se descarta. A partir de ahí, basta con pasar una imagen nueva por el encoder y leer el CLS token para obtener el embedding.

4. El embedding

Un embedding es una lista de números. Los números individualmente no significan nada, la dimensión 7 no es “vegetación” ni la dimensión 42 es “zona urbana”. El significado emerge de comparar vectores entre sí.

La métrica de comparación es la similitud coseno, que mide el ángulo entre dos vectores. Da un número entre -1 y 1: cercano a 1 significa que los dos lugares son muy similares en el espacio de embedding; cercano a 0 que no tienen relación.

Para usarlo en un modelo predictivo, el embedding es simplemente un bloque de columnas en una tabla. Las 64 dimensiones de AlphaEarth se apilan con variables del censo y se meten a un Random Forest o una regresión exactamente igual que cualquier otra covariable.

5. Los modelos que existen hoy

Hay dos familias de modelos según cómo producen el embedding:

Explícitos (Clay, Prithvi, AlphaEarth): necesitan la imagen de esa ubicación como input. Alta resolución, pero requieren datos en inferencia.

Implícitos (SatCLIP, GeoCLIP): solo necesitan coordenadas (lon, lat). El conocimiento del planeta está en los pesos de la red y se puede consultar para cualquier punto, incluso si nunca estuvo en el entrenamiento.

Modelo	Tipo	Entrenamiento	Dims	Acceso
AlphaEarth	Explícito	Multi-tarea supervisada	64	Base de datos en GEE
Clay	Explícito	MAE	768	Pesos descargables
Prithvi	Explícito	MAE multi-temporal	768	Pesos descargables
SatCLIP	Implícito	Contrastivo	512	Pesos descargables

Para este proyecto usamos AlphaEarth porque es el único que ya viene pre-computado en Google Earth Engine. No necesitamos descargar pesos, no necesitamos GPU, no necesitamos procesar imágenes: le damos una coordenada y nos devuelve el vector de 64 dimensiones. Eso lo hace el punto de entrada más natural para un proyecto de ciencias sociales.

La diferencia entre Clay y AlphaEarth en términos de objetivo de entrenamiento también importa. Clay aprende reconstruyendo patches ocultos, lo que internaliza es textura visual. AlphaEarth aprende prediciendo variables conocidas del lugar (cobertura de suelo, temperatura, elevación) todas a la vez, lo que internaliza está más orientado hacia características que describen un lugar de forma socialmente relevante. Eso explica por qué Gong et al. (2026) muestran que los 64 dims de AlphaEarth superan a los 768 de Clay comprimidos a 64: más dimensiones no ganan si el objetivo de entrenamiento es mejor.

Referencias

Klemmer, K. et al. (2025). Earth Embeddings: Towards AI-centric representations of our planet.

Brown, C. F. et al. (2025). AlphaEarth Foundations. arXiv:2507.22291.

Gong, W. et al. (2026). Earth embeddings reveal diverse urban signals from space. arXiv:2604.03456.

Dosovitskiy, A. et al. (2020). An image is worth 16x16 words. ICLR.

He, K. et al. (2022). Masked autoencoders are scalable vision learners. CVPR.