

Earth Embeddings para la Estimación del Precio de Vivienda en la Ciudad de México

Reporte de Estancia de Investigación — Maestría en Ciencia de Datos, ITAM

Manuel Alonso De la Tejera González

Supervisor: Carlos López de la Cerda

Washington University in St. Louis

Junio 2026

6. Planteamiento de la aplicación

Las secciones anteriores de este reporte establecieron la maquinaria conceptual y técnica de los Earth Embeddings: qué son, cómo se producen, qué modelos existen y cómo funciona el pipeline de extracción. Esta sección hace el puente hacia la aplicación concreta de la estancia: utilizar esos embeddings para estimar el precio de mercado de la vivienda a nivel de Área Geoestadística Básica (AGEB) en la Ciudad de México.

La pregunta de investigación es la siguiente: ¿en qué medida los Earth Embeddings de AlphaEarth capturan variación en el precio de mercado de inmuebles residenciales a nivel de AGEB en la CDMX, más allá de lo que explican las variables socioeconómicas del Censo de Población y Vivienda 2020? La intuición detrás de esta pregunta es directa: el precio de un inmueble depende no solo del perfil socioeconómico del vecindario (que el censo mide bien) sino también de características físicas del entorno que son directamente observables desde el satélite y que el censo no captura: densidad de construcción, cobertura vegetal, calidad y continuidad del tejido urbano, proximidad a infraestructura. Los Earth Embeddings, entrenados sobre imágenes de satélite de alta resolución, comprimen exactamente ese tipo de información en vectores compactos.

Esta pregunta es análoga a la que Gong et al. (2026) responden para indicadores urbanos en seis áreas metropolitanas de EE.UU., y a la que Yue et al. (2026) abordan para la estimación del PIB a nivel de país. La diferencia con esos trabajos es de escala geográfica (una sola ciudad, con granularidad de AGEB en lugar de census block group o país) y de outcome: el precio de vivienda es una variable de mercado, no un indicador censal ni una estadística oficial, lo que introduce sesgos específicos que se discuten en la siguiente sección.

7. Variable objetivo y fuentes de datos

7.1 Ground truth: precio de lista por metro cuadrado

La variable objetivo del modelo es el precio mediano de lista por metro cuadrado (MXN/m²) de inmuebles residenciales en venta, calculado dentro de cada AGEB. Los datos provienen de listings activos en Inmuebles24.com (el portal inmobiliario líder en México), extraídos durante junio de 2026.

Es importante precisar qué mide exactamente este indicador. Un precio de lista es la cifra que el vendedor publica en el portal, no el precio al que se cierra la transacción. En la Ciudad de México la diferencia promedia entre el 6% y el 12% según el segmento de mercado, con los descuentos más amplios en inmuebles de lujo y en propiedades con largo tiempo en el mercado. Esto significa que el modelo estima precios de oferta, no precios de transacción, lo cual limita su comparabilidad directa con índices como el de la Sociedad Hipotecaria Federal (SHF), que sí se basa en transacciones con crédito hipotecario.

A pesar de esta limitación, los precios de lista son el dato de mayor cobertura disponible a escala de AGEB: los registros de transacciones reales (notarías, RUV) no son públicos a esa granularidad. El trabajo de Gong et al. (2026) utiliza el mismo tipo de fuente (datos de portales inmobiliarios) para sus benchmarks, lo que hace esta elección metodológicamente consistente con la literatura.

Una segunda limitación importante es la cobertura heterogénea: AGEBs con mercado activo (Roma Norte, Polanco, Del Valle, Narvarte) concentran muchos listings; AGEBs periféricas, industriales o de muy bajo nivel socioeconómico pueden tener pocos o ninguno. El modelo solo aplica a AGEBs con al menos tres listings, lo que reduce la muestra disponible a un subconjunto de las 2,431 AGEBs urbanas de la CDMX y sesga el análisis hacia zonas con mercado formal activo.

7.2 Variables de insumo

El modelo integra tres capas de datos, cada una con una fuente y escala temporal distintas:

- Earth Embeddings de AlphaEarth (GSED V1, 2024): 64 dimensiones por AGEB, obtenidas promediando todos los píxeles de 10 metros de resolución dentro de cada polígono. AlphaEarth integra imágenes ópticas de Sentinel-2 y radar de Sentinel-1 en una representación unificada. Los embeddings están disponibles de forma gratuita en Google Earth Engine como producto de datos precalculado, lo que elimina el costo de GPU y de descarga de imágenes individuales.
- Variables socioeconómicas del Censo 2020 (INEGI): 35 indicadores a nivel de AGEB que cubren población, educación, características económicas, derechohabiencia, estructura de hogares y calidad de vivienda. Estas variables forman el modelo baseline contra el que se compara la contribución incremental de los embeddings.
- Geometrías del Marco Geoestadístico INEGI 2020: shapefile con los polígonos de las 2,431 AGEBs urbanas de la CDMX, utilizado para el join espacial de los listings de Inmuebles24 al AGEB correspondiente.

Capa	Fuente	Resolución	Año	AGEBs
Embeddings AlphaEarth	GEE — GSED V1	10 m, anual	2024	2,431
Variables censales	INEGI — Censo 2020	AGEB	2020	2,433
Ground truth	Inmuebles24.com	Listing individual	Jun. 2026	~600–900*

** AGEBs con al menos 3 listings estimadas. Dato pendiente de confirmar al resolver la extracción de datos.*

8. Diseño del MVP

8.1 Estrategia de modelado

El diseño del experimento replica la estructura incremental de Gong et al. (2026): se comparan tres modelos que se diferencian únicamente en el conjunto de variables de entrada, de forma que la diferencia de desempeño entre ellos aísla la contribución marginal de cada fuente de datos.

- Modelo A (baseline censal): regresión entrenada únicamente con las 35 variables del Censo 2020. Representa el desempeño obtenible con datos oficiales disponibles públicamente sin ninguna señal satelital.
- Modelo B (solo embeddings): regresión entrenada únicamente con los 64 componentes del embedding de AlphaEarth. Mide cuánta variación en el precio/m² captura la señal visual satelital por sí sola.
- Modelo C (censal + embeddings): regresión entrenada con ambas fuentes combinadas. El incremento de R^2 sobre el Modelo A (denotado $\Delta R^2(C-A)$) es la métrica clave: mide la contribución incremental de los embeddings sobre el baseline censal.

Para cada especificación se usa LightGBM, el mismo algoritmo que resultó más efectivo en el benchmark de Gong et al. (2026). La validación cruzada es espacial: los 5 folds se definen por agrupaciones de alcaldías (no por AGEBA aleatorias), de forma que el modelo sea evaluado sobre zonas geográficas completas que no aparecieron en el entrenamiento. Esto evita data leakage espacial, el riesgo de que el modelo aprenda la autocorrelación espacial entre AGEBA vecinas en vez de generalizar a nuevas zonas.

8.2 Evaluación

Las métricas de evaluación son R^2 (proporción de varianza en el precio/m² explicada por el modelo) y RMSE en MXN/m². El R^2 es útil para comparar entre modelos en el mismo dataset; el RMSE es interpretable en términos del negocio (¿cuántos pesos por metro cuadrado se equivoca el modelo en promedio?).

Como referencia de escala: según datos de Inmuebles24 y el indicador INBAPREVI de Banorte para enero de 2026, el precio mediano de la Ciudad de México ronda los 58,000 MXN/m², con un rango que va desde ~25,000 MXN/m² en zonas de bajo NSE (Iztapalapa, Gustavo A. Madero) hasta más de 100,000 MXN/m² en zonas de alto NSE (Polanco, Lomas). Un RMSE de 5,000–8,000 MXN/m² sería un resultado razonable para un primer MVP.

8.3 Pipeline de actualización

El diseño del pipeline sigue la lógica de un workflow reproducible con cinco pasos encadenados, descritos en orden de ejecución:

- Paso 1 — Descarga de listings: ejecución del scraper de Inmuebles24 para obtener el CSV actualizado de listings con precio, área y coordenadas (script 05_scrape_inmuebles24.py).
- Paso 2 — Limpieza y join espacial: filtrado de listings por rango de precio y área, eliminación de duplicados, y asignación de cada listing al AGEB correspondiente mediante join espacial por polígono (script 04_clean_listings.py). Resultado: precio mediano por AGEB.
- Paso 3 — Actualización de embeddings: si hay un nuevo año de GSED disponible en GEE, re-ejecución del script de extracción de embeddings para las 2,431 AGEBs (script 03_extract_alphaearth_embeddings.py). Este paso solo es necesario anualmente.
- Paso 4 — Construcción del dataset maestro: merge de las tres capas (embeddings + variables censales + ground truth) por clave AGEB. Resultado: una tabla de ~600–900 filas con todas las variables del modelo.
- Paso 5 — Entrenamiento y evaluación: ajuste de los tres modelos (A, B, C) con validación cruzada espacial. Generación del mapa de predicción y cálculo de SHAP values para interpretación.

El único componente que requiere intervención manual frecuente es el Paso 1 (scraping de listings), cuya frecuencia de actualización depende de la dinámica del mercado inmobiliario. Para los demás pasos, los scripts ya están implementados y el pipeline es reproducible sin modificaciones.

Referencias

Banorte (2026). Indicador Nacional de Precio de la Vivienda (INBAPREVI), enero 2026. Grupo Financiero Banorte.

Gong, W., Srivastava, U., Wang, Y., Jia, Y., Wu, Q., Bai, W., Yang, Y., Huang, X., & Ye, X. (2026). Earth Embeddings Reveal Diverse Urban Signals from Space. arXiv:2604.03456.

INEGI (2020). Censo de Población y Vivienda 2020 — Principales Resultados por AGEB y Manzana Urbana. Instituto Nacional de Estadística y Geografía. <https://www.inegi.org.mx/programas/ccpv/2020/>

INEGI (2020). Marco Geoestadístico Nacional 2020. Instituto Nacional de Estadística y Geografía.

Sociedad Hipotecaria Federal (2025). Índice de Precios de la Vivienda, Q3 2025. SHF — Gobierno de México.

Yue, X., Zhao, Z., & Hu, K. (2026). Estimating Economic Activity from Satellite Embeddings. *Applied Sciences*, 16(2), 582. <https://doi.org/10.3390/app16020582>